基于Python语言的ARIMA模型算法

序

时间序列数据在生产生活中极为常见。本文试图利用Python丰富的程序包,来建立适当的数学模型,对其进行描述和处理。

1、时间序列模型与ARIMA模型

时间序列的建模与预测在学术界和实际应用领域极为广泛。如股市价格、经济增长、人口数量等问题。1970年,美国的GEP Box和GM Jenkins发表了《<u>Time Series Analysis: Forecasting and Control</u>》。自那以来,逐渐形成了一整套时间序列的估计、建模和预测的理论方法。

时间序列序列数据的存在和应用十分普遍,但是其数据特点却不完全相同,如果根据数据的特点,来建立合适的模型,以反应其特点、相对准确的预测其发展趋势,是时间序列分析中的重要问题。时间序列数学建模的理论,主要是建立在随机过程的基础之上;而计算机算法的发展,则为其建模带来的极大的方便。

时间序列数据模型中,最为普遍和简单的一种,就是ARIMA模型。

1) 自回归模型 (AR, autoregression)

随机过程 $\{Y_t\}$ 如果满足: $Y_t = c + \phi_1 \cdot Y_{t-1} + \mu_t$,且 μ_t 的统计性质满足白噪音,则称 $\{Y_t\}$ 为一个AR(1)过程。如果滞后项的阶数为p,则为AR(p)过程。

2) 移动平均模型 (MA, moving average)

随机过程 Y_t 如果满足: $Y_t = c + \theta \cdot \mu_{t-1} + \mu_t$,且 μ_t 的统计性质满足白噪音,则称 $\{Y_t\}$ 为一个MA(q)过程。如果滞后项的阶数为q,则为MA(q)过程。

3)ARMA与ARIMA模型

随机过程 Y_t 如果满足: $Y_t = c + \phi \cdot Y_{t-1} + \theta \cdot \mu_{t-1} + \mu_t$,且 μ_t 的统计性质满足白噪音,则称 $\{Y_t\}$ 为一个ARMA(1,1)过程。如果自回归项的滞后阶数为p,移动平均项滞后阶数为q,则为ARMA(p,q)模型。

如果其中包含单位根过程,且单位根的阶数为1,则为ARIMA(p,1,q)过程。

当ARIMA(p,1,q)模型建立之后,通常需要对模型进行检验,以判断模型的拟合程度和预测准确度。通常的检验包括:

2、Python语言处理时间序列模型

下面试着用Python语言来处理时间序列模型。

首先导入计算模块。pandas, numpy, scipy, 和statsmodels是常用的数理统计模块, matplotlib则是常用的数据可视化的模块, 在这里导入用来观察数据的趋势。

```
from __future__ import print_function
import pandas as pd
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt
import statsmodels.api as sm
from statsmodels.graphics.api import qqplot
```


然后,输入数据。这是一个包含90个观测值的时间序列数据。

```
#input the data
dta=
[10930,10318,10595,10972,7706,6756,9092,10551,9722,10913,11151,8186,6422,6337,11649,11652,10310,
12043,7937,6476,9662,9570,9981,9331,9449,6773,6304,9355,10477,10148,10395,11261,8713,7299,10424,
10795,11069,11602,11427,9095,707,10767,
12136,12812,12006,12528,10329,7818,11719,11683,12603,11495,13670,11337,10232,13261,13230,15535,1
6837,19598,14823,11622,19391,18177,19994,14723,15694,13248,
9543,12872,13101,15053,12619,13749,10228,9725,14729,12518,14564,15085,14722,
11999,9390,13481,14795,15845,15271,14686,11054,10395]
```

然后,我们对数据进行初步的检查和处理。


```
## change data type
dta=np.array(dta,dtype=np.float)
dta=pd.Series(dta)
dta.index = pd.Index(sm.tsa.datetools.dates_from_range('1911','2000'))
dta.plot(figsize=(12,8))
# general view of the data
dta.plot(figsize=(12,8))
plt.show()
```

可以得到下图:




然后,我们对数据进行一阶差分,使其变得更为平稳。

```
## difference 1-order
fig = plt.figure(figsize=(12,8))
ax1= fig.add_subplot(111)
diff1 = dta.diff(1)
diff1.plot(ax=ax1)
plt.show()
```



如果不满意,可以继续进行二阶差分。


```
## difference 2-order
fig = plt.figure(figsize=(12,8))
ax2= fig.add_subplot(111)
diff2 = dta.diff(2)
diff2.plot(ax=ax2)
plt.show()
```



但是由于一阶差分的结果已经能够满足平稳,而且相对模型更为简单。所以之后的分析以一阶差分为基础。

为了确定自回归和移动平均的阶数,通常的一个简单的办法是观察自相关 (acf, autocorrelation function) 和偏自相关(pacf, partial autocorrelation funcition) 系数的情况。于是我们对一阶差分的acf和pacf作图观察。

```
## acf and pacf
diff1= dta.diff(1)
dta=dta.diff1
fig = plt.figure(figsize=(12,8))
ax1=fig.add_subplot(211)
fig = sm.graphics.tsa.plot_acf(dta,lags=40,ax=ax1)
ax2 = fig.add_subplot(212)
fig = sm.graphics.tsa.plot_pacf(dta,lags=40,ax=ax2)
plt.show()
```




这里的自相关系数拖尾,偏自相关系数截尾,而且偏自相关在lag=8时有明显截尾的趋势,所以通过AIC和BIC准则对模型的AR(7)或AR(8)进行比较。

```
## model specification, AIC and BIC
arma_mod70 = sm.tsa.ARMA(dta,(7,0)).fit()
print(arma_mod70.aic,arma_mod70.bic,arma_mod70.hqic)
arma_mod30 = sm.tsa.ARMA(dta,(0,1)).fit()
print(arma_mod30.aic,arma_mod30.bic,arma_mod30.hqic)
arma_mod71 = sm.tsa.ARMA(dta,(7,1)).fit()
print(arma_mod71.aic,arma_mod71.bic,arma_mod71.hqic)
arma_mod80 = sm.tsa.ARMA(dta,(8,0)).fit()
print(arma_mod80.aic,arma_mod80.bic,arma_mod80.hqic)
```

最终确定AR的滞后阶数为8,MA的滞后阶数为0,即模型为*ARIMA*(8,1,0)模型(进行了一次差分)。 然后对模型进行进一步的检验。

• 对残差的检验: 通过残差的ACF和PACF可以看出, 残差基本满足白噪声的条件。


```
## residual
resid = arma_mod80.resid
fig = plt.figure(figsize=(12,8))
ax1 = fig.add_subplot(211)
fig = sm.graphics.tsa.plot_acf(resid.values.squeeze(), lags=40, ax=ax1)
ax2 = fig.add_subplot(212)
fig = sm.graphics.tsa.plot_pacf(resid, lags=40, ax=ax2)
plt.show()
```



• 对正态性的检验。结果看,正态性的条件符合得很好。

```
##Normarity test
print(stats.normaltest(resid))
fig = plt.figure(figsize=(12,8))
ax = fig.add_subplot(111)
fig = qqplot(resid, line='q', ax=ax, fit=True)
plt.show()
```

NormaltestResult(statistic=14.604690828509506, pvalue=0.00067395621352767988)



• D-W 检验。检验残差项的自相关情况。

```
##D-W test
print(sm.stats.durbin_watson(arma_mod80.resid.values))
```

2.04167903544

• Ljunng-Box 检验。对模型的拟合效果进行综合检验。(输出略)

```
##Ljunng-Box test
r,q,p = sm.tsa.acf(resid.values.squeeze(), qstat=True)
data = np.c_[range(1,41), r[1:], q, p]
table = pd.DataFrame(data, columns=['lag', "AC", "Q", "Prob(>Q)"])
print(table.set_index('lag'))
```

3、总结

利用程序语言进行时间序列的分析,可以大大提高效率。在已有的成熟的统计软件如Stata/SAS/Eviews等中,已经有了处理时间序列数据的相关内置函数或程序包,但是无论是计算效率、数据可视化的能力,还是灵活程度、开源性,都远远逊色于Python。本文仅仅对Python语言处理ARIMA模型进行简单的讨论和学习,希望能随着Python语言和算法的深入学习,掌握更多的处理ARIMA等时间序列模型的技巧。

参考文献:

- Autoregressive Moving Average (ARMA): Sunspots data, url:
 http://statsmodels.sourceforge.net/devel/examples/notebooks/generated/tsa_arma_0.html#autoregressive-moving-average-arma-sunspots-data.
 sunspots-data.
 sunspots-dat
- 2. Python_Statsmodels包时间序列分析ARIMA模型, url:http://blog.csdn.net/hal_sakai/article/details/51965657.
- 3. [美]沃尔特·恩德斯(著),杜江、谢志超(译).应用计量经济学——时间序列分析(第2版),高等教育出版社.
- 4. 涂云东,时间序列分析课堂讲义.
- 5. 周广旭. (2005). 一种新的时间序列分析算法及其在股票预测中的应用. 计算机应用, 25(9), 2179-2181.